

lab1

Mateus Bortolucci

2026-08-18

```
library(tidyverse)
```

```
## -- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
## v dplyr      1.2.1      v readr      2.2.0
## v forcats    1.0.1      v stringr    1.6.0
## v ggplot2     4.0.3      v tibble     3.3.1
## v lubridate  1.9.5      v tidyr      1.3.2
## v purrr       1.2.2
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()     masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become errors
```

```
table1
```

```
## # A tibble: 6 x 4
##   country      year cases population
##   <chr>      <dbl> <dbl>      <dbl>
## 1 Afghanistan 1999     745  19987071
## 2 Afghanistan 2000    2666  20595360
## 3 Brazil      1999   37737  172006362
## 4 Brazil      2000   80488  174504898
## 5 China       1999 212258 1272915272
## 6 China       2000 213766 1280428583
```

```
table2
```

```
## # A tibble: 12 x 4
##   country      year type      count
##   <chr>      <dbl> <chr>      <dbl>
## 1 Afghanistan 1999 cases         745
## 2 Afghanistan 1999 population 19987071
## 3 Afghanistan 2000 cases         2666
## 4 Afghanistan 2000 population 20595360
## 5 Brazil      1999 cases         37737
## 6 Brazil      1999 population 172006362
## 7 Brazil      2000 cases         80488
## 8 Brazil      2000 population 174504898
## 9 China       1999 cases        212258
## 10 China       1999 population 1272915272
## 11 China       2000 cases        213766
## 12 China       2000 population 1280428583
```

```
table3
```

```
## # A tibble: 6 x 3
##   country      year rate
##   <chr>      <dbl> <chr>
## 1 Afghanistan 1999 745/19987071
## 2 Afghanistan 2000 2666/20595360
## 3 Brazil      1999 37737/172006362
## 4 Brazil      2000 80488/174504898
## 5 China       1999 212258/1272915272
## 6 China       2000 213766/1280428583
```

```
table4a
```

```
## # A tibble: 3 x 3
##   country      '1999' '2000'
##   <chr>      <dbl> <dbl>
## 1 Afghanistan    745    2666
## 2 Brazil        37737   80488
## 3 China        212258  213766
```

```
table4b
```

```
## # A tibble: 3 x 3
##   country      '1999'      '2000'
##   <chr>      <dbl>      <dbl>
## 1 Afghanistan 19987071    20595360
## 2 Brazil      172006362   174504898
## 3 China       1272915272  1280428583
```

A table1 esta no formato tidy, pois cada variável tem uma coluna, cada observação tem uma linha e cada valor tem uma célula

Na table2, as variáveis reais do nosso conjunto de dados (cases e population) não têm colunas próprias.

A table3 não é tidy porque nela cada célula não contém apenas um único valor, já que rate contém os casos e a população separados por uma barra (/).

Já a table4a e table4b não estão no formato tidy porque em ambas há colunas que são valores e não variáveis

```
taxas <- table1 |>
  mutate(taxa_10k = (cases / population) * 10000)
```

```
table1 |> group_by(year) |> summarise(sum(cases))
```

```
## # A tibble: 2 x 2
##   year 'sum(cases)'
##   <dbl>      <dbl>
## 1 1999    250740
## 2 2000    296920
```

```
table1 |> group_by(country) |> summarise(sum(cases))
```

```
## # A tibble: 3 x 2
##   country      'sum(cases)'  
##   <chr>          <dbl>  
## 1 Afghanistan    3411  
## 2 Brazil         118225  
## 3 China          426024
```


```
table1 |> group_by(country) |> summarise(mudanca_casos = cases[year == 2000] - cases[year == 1999])
```

```
## # A tibble: 3 x 2  
##   country      mudanca_casos  
##   <chr>          <dbl>  
## 1 Afghanistan    1921  
## 2 Brazil         42751  
## 3 China          1508
```

```
ggplot(data = taxas, aes(x = year, y = taxa_10k, color = country)) +  
  geom_line(linewidth = 1) +  
  geom_point(size = 3) +  
  scale_x_continuous(breaks = c(1999, 2000)) +  
  labs(  
    title = "Evolução da Taxa de Tuberculose por País (1999-2000)",  
    subtitle = "Casos a cada 10.000 habitantes",  
    x = "Ano",  
    y = "Taxa (por 10 mil hab.)",  
    color = "País"  
  ) +  
  theme_minimal()
```

Evolução da Taxa de Tuberculose por País (1999–2000)

Casos a cada 10.000 habitantes



```
tidy4a <- table4a %>%
  pivot_longer(
    cols = c(`1999`, `2000`),
    names_to = "year",
    values_to = "cases"
  ) %>%
  mutate(year = as.integer(year))

tidy4b <- table4b %>%
  pivot_longer(
    cols = c(`1999`, `2000`),
    names_to = "year",
    values_to = "population"
  ) %>%
  mutate(year = as.integer(year))


tidy2 <- table2 %>%
  pivot_wider(
    names_from = type,
    values_from = count
  )

taxas_table2 <- tidy2 %>%
  mutate(taxa_10k = (cases / population) * 10000)
```

```
ggplot(data = taxas_table2, aes(x = year, y = taxa_10k, color = country)) +
  geom_line(linewidth = 1) +
  geom_point(size = 3) +
  scale_x_continuous(breaks = c(1999, 2000)) + # Garante que o eixo X mostre apenas anos exatos
  labs(
    title = "Evolução da Taxa de Tuberculose por País (1999-2000)",
    subtitle = "Fonte: table2 transformada (Casos por 10.000 habitantes)",
    x = "Ano",
    y = "Taxa (por 10 mil hab.)",
    color = "País"
  ) +
  theme_minimal()
```

Evolução da Taxa de Tuberculose por País (1999-2000)

Fonte: table2 transformada (Casos por 10.000 habitantes)



```
tidy4a <- table4a %>%
  pivot_longer(
    cols = c(`1999`, `2000`),
    names_to = "year",
    values_to = "cases"
  )
```

```
tidy4b <- table4b %>%
  pivot_longer(
    cols = c(`1999`, `2000`),
    names_to = "year",
```

```
  values_to = "population"
)
```

```
tidy4 <- left_join(tidy4a, tidy4b, by = c("country", "year"))
```

O comando `left_join` uniu duas tabelas com base em colunas em comum (as “chaves”, que neste caso são `country` e `year`).

```
table2_tidy <- table2 %>%
  pivot_wider(
    names_from = type,
    values_from = count
  )
```

```
table3_tidy <- table3 %>%
  separate(
    col = rate,
    into = c("cases", "population"),
    sep = "/",
    convert = TRUE
  )
```